

AGGIORNAMENTO LAVORO di TESI di ELISABETTA ROVIERA

TITOLO. DNA Methylation Dynamics Along the Normal-Adjacent Axis in Breast Cancer

SOTTOTITOLO. A Quantitative Statistical and Machine Learning Approach

REPOSITORY. Il codice (Python/R) e i report sono disponibili nella repository: <https://github.com/elisabettaroviera/THESIS>

OBIETTIVO. Identificare le CpG la cui metilazione distingue il tessuto mammario istologicamente normale dal tessuto adiacente al tumore, per caratterizzare uno stato epigenetico precoce lungo l'asse Normal → Adjacent → Tumor.

DATI. Sono stati analizzati tre dataset pubblici di metilazione del DNA su tessuto mammario, generati con piattaforme Illumina **HM450** ed **EPIC**.

Dataset	Piattaforma	Normal Sample	Adjacent Sample	Tumor Sample	N° CpG Iniziali
GSE69914	HM450	50	42	305	485.512
GSE225845	EPIC	113	140	224	750.426
GSE287331	EPIC	182	60	69	866.552

DATA EXPLORATION & VISUALIZATION. Sono state analizzate le distribuzioni globali dei β -values, il Mean| $\Delta\beta$ | (Adjacent-Normal), il rapporto Var(A)/Var(N), l'outlier burden ratio (A/N), la separazione multivariata tramite **PCA**, **t-SNE** e **UMAP** con silhouette score (A/N), e proxy dinamici gene-level (degree-rank e layout DNB-like).

Dataset	Evidenze principale
GSE69914	<u>Differenze</u> Normal-Adjacent globalmente <u>molto contenute</u> ; segnale prevalentemente locus-specifico e separazione multivariata debole.
GSE225845	<u>Drift epigenetico più evidente</u> in termini di dispersione e outlier burden, ma cluster Normal-Adjacent ancora parzialmente sovrapposti.
GSE287331	<u>Separazione multivariata netta</u> tra Normal e Adjacent, aumento marcato dell'outlier burden e struttura di drift biologicamente organizzata.
Cross-dataset	Il drift epigenetico lungo l'asse Normal → Adjacent è osservabile in tutte le coorti, ma con intensità eterogenea.

DATA PRE-PROCESSING. È stato applicato un pre-processing armonizzato comprendente diagnosi del bias Infinium Type I/II, technical filtering mediante esclusione delle sonde segnalate dalle liste Naeem, Pidsley, Zhou, Chen e McCartney, filtraggio basato su manifest Illumina (rimozione sonde non-CpG o prive di coordinate valide), esclusione delle CpG su cromosomi X/Y e trasformazione $\beta \rightarrow M$ -values per stabilizzazione della varianza.

Dataset	N° CpG finali	Evidenza principale
GSE69914	251.483	<u>Dataset completo</u> , bias Type I/II correttamente mitigato.
GSE225845	530.683	Piattaforma EPIC con elevata dimensionalità iniziale, <u>dataset completo</u> .
GSE287331	486.725	Presenza di <u>missingness</u> e <u>bias Type I/II non corretto</u> ; applicato <u>filtro rimozione NaN $\leq 1\%$ + imputazione mediana</u> ; BMIQ testato ma non adottato.
Cross-dataset	215.919 (n comune)	Technical filtering riduce artefatti piattaforma-specifici.

AGE. È stata stimata l'età epigenetica (Horvath multi-tissue clock, 353 CpG) sui campioni Normal e Adjacent, ottenendo su GSE225845 una correlazione $R=0.77$ ($MAE \approx 10$ anni) e un age acceleration globale positiva (+7.6 anni), con accelerazione più marcata nei Normal rispetto agli Adjacent.

FEATURE SELECTION & CLASSIFICATORE. La pipeline è applicata sul training set (split 80/20 stratificato). (1) Le CpG con range inter-percentile ($P_{90}-P_{10}$) < 0.05 sui β -values vengono eliminate tramite filtro Edgar; il set risultante viene trasformato in M-values e ulteriormente ridotto rimuovendo il 2% a varianza più bassa. (2) Il ranking delle CpG candidate si basa su repeated stratified K-fold ($K=5$, $R=10$): per ogni split viene calcolato uno score statistico combinato (p-value Mann-Whitney U e $|\Delta M|$ tra Adjacent e Normal, pesati equamente), integrato con un peso biologico che privilegia le CpG in CpG island e/o promotore (TSS), con contributo del 20% sullo score finale. Vengono trattenute solo le CpG con stabilità del segno $\geq 75\%$ tra fold e $|\Delta M| \geq 60^\circ$ percentile, producendo un pool di ~ 15.000 candidate. (3) Le CpG candidate vengono poi ancorate a CpG island: per ogni regione con almeno 2 CpG stabili, vengono selezionate le 2-3 rappresentanti con score migliore (Pool A); le restanti formano il Pool B. Su entrambi i pool separatamente, il clustering per correlazione (Spearman $|r| \geq 0.85$, componenti connesse) riduce la ridondanza trattenendo un solo rappresentante per cluster. (4) Il set risultante viene infine diversificato con vincoli soft su cromosoma ($\leq 20\%$), contesto genomico ($\leq 65\%$) e densità spaziale (≤ 15 CpG per 500kb), producendo le 5.000 CpG finali utilizzate per addestrare la SVM. (5) Su GSE287331 e GSE225845 è stata addestrata una LinearSVC ($C=0.5$, class weight="balanced", max_iter=10.000); su GSE69914 è stato utilizzato un Ridge classifier ($\alpha=1$, class weight="balanced"). I risultati mostrano buona classificazione intra-dataset, poca capacità di generalizzare.

Train \ Test Dataset	GSE69914	GSE225845	GSE287331
GSE69914	<u>0.7111</u>	0.621	0.2958
GSE225845	0.5500	<u>0.9570</u>	0.0444
GSE287331	0.4357	0.4183	<u>1.0000</u>

KNAPSACK PROBLEM & GENE SET ANALYSIS. Dal pool delle 5.000 CpG candidate, la selezione finale di 50 CpG viene formulata come un problema di ottimizzazione combinatoria (MILP) che massimizza simultaneamente la rilevanza classificatoria (score combinato di coefficiente SVM, $|\Delta M|$ e score RSKF) e la struttura biologica del set (copertura di promotori, CpG island e geni distinti), con un prior additivo per i geni driver del cancro al seno presenti nel COSMIC Cancer Gene Census. I vincoli hard garantiscono cardinalità esatta ($K=50$), assenza di CpG ridondanti ($|r| \geq 0.85$), bilanciamento cromosomico (≤ 10 CpG per cromosoma), copertura minima di Pool A, massimo 2 CpG per gene e almeno 15 CpG ipermetilate in Adjacent. I geni associati alle 50 CpG selezionate sono stati annotati tramite il manifest Illumina EPIC e confrontati con il COSMIC Cancer Gene Census (v103) e un insieme di geni noti nel field cancerization mammario, per valutare la coerenza biologica del set finale.

Le 50 CpG selezionate mostrano una buona capacità discriminativa. Su GSE225845, la separazione Normal-Adjacent raggiunge $AUC=0.855$ (± 0.073) con silhouette=0.065, mentre la separazione Normal-Tumor risulta più netta ($AUC=0.901 \pm 0.055$, silhouette=0.120), coerentemente con l'attesa che il segnale epigenetico si accentui lungo l'asse Normal→Adjacent→Tumor. Su GSE287331 si osserva $AUC=1.0$ in entrambe le comparazioni, da interpretare con cautela data la ridotta numerosità del test set ($n=49$, di cui 12 Adjacent), che rende la stima poco affidabile.

CpG - GSE287331	Gene	Direzione in Adjacent	Ruolo nel carcinoma mammario
cg15957959	AKT1	Hypermethylated	Oncogene centrale nella via PI3K/AKT/mTOR, frequentemente attivato nel carcinoma mammario
cg00920970	ESR1	Hypomethylated	Recettore degli estrogeni, oncogene e TSG; alterazioni epigenetiche associate alla resistenza endocrina
cg15267232	GATA3	Hypomethylated	Fattore di trascrizione master del sottotipo luminale; loss-of-function associata a progressione tumorale
cg18481241	RB1	Hypomethylated	TSG; la perdita di funzione favorisce la progressione del ciclo cellulare nel carcinoma mammario
cg22635491	TBX3	Hypomethylated	Oncogene e TSG; coinvolto nello sviluppo della ghiandola mammaria e nella transizione epitelio-mesenchima

CpG - GSE225845	Gene	Direzione in Adjacent	Ruolo nel carcinoma mammario
cg25095814	CASP8	Hypomethylated	TSG; regola l'apoptosi; la sua silenziamento epigenetico è documentato nel carcinoma mammario
cg13271751	CCND1	Hypermethylated	Oncogene; amplificato nel carcinoma mammario luminale, regola il checkpoint G1/S
cg19209049	CCND1	Hypomethylated	Seconda CpG sullo stesso gene, direzione opposta
cg25801292	KEAP1	Hypomethylated	TSG; regola la risposta antiossidante via NRF2; alterato nel carcinoma mammario
cg25801292	KEAP1	Hypomethylated	Seconda CpG sullo stesso gene, stessa direzione
cg17420463	MAP3K13	Hypomethylated	Oncogene e TSG; coinvolto nella via NF-κB, associato a carcinoma mammario
cg17420463	MAP3K13	Hypomethylated	Seconda CpG sullo stesso gene, stessa direzione
cg04689697	NCOR1	Hypomethylated	TSG; co-repressore trascrizionale; mutato nel carcinoma mammario luminale
cg01753796	PIK3CA	Hypermethylated	Oncogene; uno dei geni più frequentemente mutati nel carcinoma mammario
cg12697442	YAP1	Hypomethylated	Effettore della via Hippo; ruolo nell'invasività e nella resistenza terapeutica nel carcinoma mammario

CpG - GSE69914	Gene	Direzione in Adjacent	Ruolo nel carcinoma mammario
MANCA			

NEXT STEPS. I classificatori lineari mostrano buone performance intra-dataset, ma generalizzazione cross-dataset limitata, suggerendo effetti piattaforma-specifici e dipendenze non lineari non catturate dal modello. Si propone quindi di combinare i due dataset EPIC, costruire uno split train/test stratificato per classe e coorte, stimare ComBat (bach effect correction) sul solo train e applicarlo al test, quindi addestrare CpGPT sul train armonizzato e valutarne la performance e la coerenza biologica tramite nuova gene set analysis.