



DNA Methylation Dynamics Along the Normal-Adjacent Axis in Breast Cancer

A Quantitative Statistical and Machine Learning Approach

Laurea Magistrale in Ingegneria Matematica

Elisabetta ROVIERA (328422)

Relatori: Prof. Alfredo BENSO

Dott. Sandro GAMBINO

16 Marzo 2026



**Politecnico
di Torino**



Table of Contents


1 Dal Problema Biologico ai Dati

- ▶ Dal Problema Biologico ai Dati
- ▶ Dal Dato Grezzo alla Feature Selection
- ▶ Dal MILP alla Soluzione
- ▶ Dalle Conclusioni agli Sviluppi Futuri



Il Tumore al Seno: una Sfida Globale


1 Dal Problema Biologico ai Dati



Tumore più comune per paese — GLOBOCAN 2022

In rosa è riportato il tumore al seno

- **2.3 milioni** di nuovi casi
- Più diagnosticato in **82 su 185** paesi



Tessuto tumorale, adiacente e normale a confronto —


Gadaleta et al., J Pathol, 2022

- **Alterazioni epigenetiche precoci**
- **Distinguere Normale da Adiacente**




Metilazione del DNA: Segnale Biologico e Statistico

1 Dal Problema Biologico ai Dati



$\beta\text{-value} \in [0, 1]$



$$M = \log_2\left(\frac{\beta}{1-\beta}\right) \in (-\infty, +\infty)$$

Metilazione del DNA

- **Ipermetilazione** → gene silenziato
- **Ipometilazione** → gene attivo

Illumina EPIC ~866k siti CpG

- **295** Normali
- **200** Adiacenti



Table of Contents


2 Dal Dato Grezzo alla Feature Selection

- ▶ Dal Problema Biologico ai Dati
- ▶ Dal Dato Grezzo alla Feature Selection
- ▶ Dal MILP alla Soluzione
- ▶ Dalle Conclusioni agli Sviluppi Futuri




Preprocessing: dal Rumore al Segnale

2 Dal Dato Grezzo alla Feature Selection




β -value grezzo

Segnale biologico e tecnico sovrapposti



Post- $|\beta_{ij} - \bar{\beta}_j^{\text{Normal}}|$

Deviazione dal tessuto sano amplificata




Post-NeuroCombat

Batch rimosso, segnale preservato



Riduzione dello Spazio delle Feature


2 Dal Dato Grezzo alla Feature Selection





Stability Ranking


2 Dal Dato Grezzo alla Feature Selection






Correlation Pruning tramite Grafi

2 Dal Dato Grezzo alla Feature Selection



Arco se $|r| \geq 0.85$



Pool A: CpG ancorati a CpG islands (biologicamente privilegiati)

Pool B: restanti CpG candidati



Table of Contents

3 Dal MILP alla Soluzione

- ▶ Dal Problema Biologico ai Dati
- ▶ Dal Dato Grezzo alla Feature Selection
- ▶ Dal MILP alla Soluzione
- ▶ Dalle Conclusioni agli Sviluppi Futuri



Selezione delle CpG Finali: MILP Knapsack

$$\max_x \sum_{j \in \mathcal{J}} v_j x_j + \mu \cdot \hat{\Phi}(x, \gamma)$$

$$\text{s.t.} \quad \sum_{j \in \mathcal{J}} x_j = 50$$

(Cardinalità)

$$\sum_{j \in \mathcal{J}_c} x_j \leq 10 \quad \forall c$$

(Bilanciamento cromosomico)

$$\sum_{j: g(j)=g} x_j \leq 2 \quad \forall g$$

(Max CpG per gene)

$$x_j \leq \gamma_{g(j)} \leq \sum_{j': g(j')=g} x_{j'} \quad \forall j: g(j) \neq \emptyset$$

(Gene linking)

$$x_i + x_j \leq 1 \quad \forall (i, j) : |r_{ij}| \geq 0.85$$

(Non-ridondanza)


$$x_j, \gamma_g \in \{0, 1\}$$

→ Formulazione completa in appendice.



Risultati: il Trade-off Esplicito

3 Dal MILP alla Soluzione



Approccio	AUC	BACC	COSMIC
Baseline	0.952	0.90	1
Greedy top-50	0.982	0.92	0
MILP knapsack	0.974	0.91	13

COSMIC: geni nel Cancer Gene Census
con annotazione breast cancer

Decision boundary nello spazio PCA dei 50 CpG
selezionati



Interpretabilità Biologica

3 Dal MILP alla Soluzione

■ RB1

Tumor suppressor

- **Ruolo:** regolatore principale del ciclo cellulare
- **Rilevanza:** tra i marcatori più consolidati di field cancerization mammaria

● NOTCH1

Segnalazione

- **Ruolo:** mantenimento cellule staminali tumorali
- **Rilevanza:** promuove progressione verso fenotipi invasivi

▲ AKT1

Segnalazione

- ▲ **Ruolo:** kinasi centrale del pathway PI3K/AKT/mTOR
- ▲ **Rilevanza:** tra i più alterati nel carcinoma mammario, bersaglio di terapie mirate approvate

◆ TBX3

Fattore di trascrizione

- ◆ **Ruolo:** regola l'identità cellulare mammaria
- ◆ **Rilevanza:** alterazione epigenetica associata a perdita di differenziazione nel carcinoma luminale

→ Lista completa in appendice.



Table of Contents

4 Dalle Conclusioni agli Sviluppi Futuri

- ▶ Dal Problema Biologico ai Dati
- ▶ Dal Dato Grezzo alla Feature Selection
- ▶ Dal MILP alla Soluzione
- ▶ Dalle Conclusioni agli Sviluppi Futuri



Conclusioni

4 Dalle Conclusioni agli Sviluppi Futuri

Le 50 CpG dimostrano che **performance e interpretabilità biologica non sono in conflitto**



Feature Selection

866k → 5.000 CpG stabili e
non ridondanti



MILP Knapsack

Biologia come vincolo
strutturale



Pannello 50 CpG

AUC 0.974
13 geni COSMIC breast



Validazione Multi-dataset

Segnale riproducibile su due
coorti EPIC indipendenti



Limitazioni e Sviluppi Futuri

4 Dalle Conclusioni agli Sviluppi Futuri



Limitazioni

Validazione esterna

Nessun dataset EPIC indipendente dalla pipeline

Cross-piattaforma

Mancata trasferibilità a HM450K



Sviluppi Futuri

Altri tumori

Framework MILP parametrizzabile per colon, ovaio

Integrazione multi-omica

RNA-seq per confermare il ruolo funzionale delle CpG



DNA Methylation Dynamics Along the Normal-Adjacent Axis in Breast Cancer

Grazie mille per l'attenzione!



Appendice — NeuroCombat

4 Dalle Conclusioni agli Sviluppi Futuri


Modello di batch correction

$$Y_{ijd} = \alpha_j + X\beta_j + \gamma_{jd} + \delta_{jd} \varepsilon_{ijd}$$


- α_j — media globale del CpG j
- $X\beta_j$ — effetto delle covariate biologiche protette:
tissue label + età
- γ_{jd} — effetto additivo del batch d
- δ_{jd} — effetto moltiplicativo del batch d
- γ_{jd}, δ_{jd} stimati via **Empirical Bayes shrinkage**

Parametri stimati **solo su train**; applicati al test via `neuroCombatFromTraining` — zero leakage.

Pre-ComBat



Post-ComBat





Appendice — Filtro di Variabilità (Edgar)

4 Dalle Conclusioni agli Sviluppi Futuri


Statistica di variabilità

$$r_{\beta,j} = Q_{0.90}(\beta_j \mid \mathcal{D}_{\text{train}}) - Q_{0.10}(\beta_j \mid \mathcal{D}_{\text{train}})$$

Un CpG è ritenuto se e solo se:

$$r_{\beta,j} \geq \tau, \quad \tau = 0.05$$

- **Filtro non supervisionato** — calcolato senza etichette di classe
- **Stimato solo su train** — applicato identicamente al test
- **Risultato:** 866k $\rightarrow$ $\sim$ 285k-485k CpG a seconda della coorte





Appendice — Filtro Varianza in M-space


4 Dalle Conclusioni agli Sviluppi Futuri

Residual variance trimming

$$SD_j = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (M_{ij} - \bar{M}_j)^2}$$

Un CpG è rimosso se: $SD_j < SD^*$

- **Motivazione** — la mappa logit è non lineare: loci con $r_{\beta,j}$ basso ma concentrati ai bordi di $[0, 1]$ producono M-value quasi costanti
- **Soglia data-driven** — primo minimo locale della distribuzione $SD(M)$ sul train, che separa i loci quasi-costanti dallo spazio discriminativo principale
- **Risultato:** rimozione di $\sim 3k-8k$ CpG residui a seconda della coorte





Appendice — Diversificazione Genomica Vincolata

4 Dalle Conclusioni agli Sviluppi Futuri

Selezione greedy vincolata

$$\min_{S \subseteq \mathcal{R}} \sum_{j \in S} \text{score}_j$$

$$\text{s.t. } |S| = K_{\text{eff}}$$


$$|\{j \in S : c(j) = \chi\}| \leq \lfloor \alpha_{\text{chr}} K_{\text{eff}} \rfloor \quad \forall \chi$$

$$|\{j \in S : \gamma(j) = g\}| \leq \lfloor \alpha_{\text{ctx}} K_{\text{eff}} \rfloor \quad \forall g$$

$$|\{j \in S : w(j) = \omega\}| \leq B_{\omega} \quad \forall \omega$$

con $\alpha_{\text{chr}} = 0.08$, $\alpha_{\text{ctx}} = 0.65$, $B_{\omega} = 15$.

- **Cardinalità** — esattamente $K = 5.000$ CpG
- **Cromosomica** — max 8% per cromosoma
- **Contesto genomico** — max 65% per classe (Island, Shore, OpenSea...)
- **Finestra spaziale** — max 15 CpG per finestra da 500kb





Appendice — Formulazione completa MILP

$$\max_x \underbrace{\sum_{j \in \mathcal{J}} \left(\underbrace{w_{\text{coef}} \tilde{c}_j}_{\text{coeff. SVM}} + \underbrace{w_{\Delta M} \tilde{d}_j}_{|\Delta M|} + \underbrace{w_{\sigma} \tilde{s}_j}_{\text{stabilità}} + \underbrace{w_{\text{COSMIC}} \mathbf{1}_{j \in \text{CGC}}}_{\text{gene noto}} \right) x_j}_{\text{score composito}} + \mu \cdot \underbrace{\frac{1}{K(2 + \eta)} \left(\sum_{j: \text{prom}(j)} x_j + \sum_{j: \text{isl}(j)} x_j + \eta \sum_g \gamma_g \right)}_{\hat{\Phi}(x, \gamma)}$$

$$\text{s.t.} \quad \sum_{j \in \mathcal{J}} x_j = 50$$

$$\sum_{j \in \mathcal{J}_c} x_j \leq 10 \quad \forall c$$

$$\sum_{j: g(j)=g} x_j \leq 2 \quad \forall g$$

$$x_j \leq \gamma_{g(j)} \leq \sum_{j': g(j')=g} x_{j'} \quad \forall j: g(j) \neq \emptyset$$

$$x_i + x_j \leq 1 \quad \forall (i, j) : |r_{ij}| \geq 0.85$$

$$5/7 \quad x_j, \gamma_g \in \{0, 1\}$$




Appendice — Estensione a una Diversa Piattaforma

4 Dalle Conclusioni agli Sviluppi Futuri

GSE69914 e GSE67919 — HM450K

Il pannello da 50 CpG è stato derivato su array **EPIC**.
L'estensione a HM450K introduce due limitazioni strutturali:

- **Copertura ridotta** — HM450K interroga ~450k sonde vs ~866k di EPIC: non tutte le 50 CpG sono presenti su entrambi i dataset
- **Sonde non equivalenti** — le sonde condivise non sono garantite avere lo stesso comportamento chimico
- **Risultato** — le distribuzioni di $|\beta - \mu_{\text{Normal}}|$ su HM450K sono più larghe e meno separate rispetto alle coorti EPIC



La validazione cross-piattaforma richiede una pipeline dedicata — identificata come sviluppo futuro.



Appendice — Tutti i Geni COSMIC nel Pannello

4 Dalle Conclusioni agli Sviluppi Futuri

Gene	Categoria	Gene	Categoria
RB1	Tumor suppressor	AKT1	Segnalazione
TBX3	Fattore di trascrizione	NOTCH1	Segnalazione
NCOR1	Regolatore cromatina	MAP2K4	Segnalazione
SMARCD1	Regolatore cromatina	FGF8	Fattore di crescita
SALL4	Fattore di trascrizione	WNT5A	Segnalazione
PLEC	Strutturale	TYRO3	Recettore tirosina kinasi
FBLN2	Matrice extracellulare		

Fisher exact test (one-sided): arricchimento significativo rispetto al background EPIC ($p < 0.001$).