



DNA Methylation Dynamics Along the Normal-Adjacent Axis in Breast Cancer

A Quantitative Statistical and Machine Learning Approach

Laurea Magistrale in Ingegneria Matematica

Elisabetta ROVIERA (328422)

Relatori: Prof. Alfredo BENSO

Dott. Sandro GAMBINO

16 Marzo 2026



**Politecnico
di Torino**



Table of Contents


1 Dal Problema Biologico ai Dati

- ▶ Dal Problema Biologico ai Dati
- ▶ Dal Dato Grezzo alla Feature Selection
- ▶ Dalla Feature Selection al Pannello Finale
- ▶ Conclusioni e Sviluppi Futuri




Il Tumore al Seno: una Sfida Globale

1 Dal Problema Biologico ai Dati



Tumore più comune per paese — GLOBOCAN 2022

- **2.3 milioni** di nuovi casi (2022)
- Tumore più diagnosticato in **82 su 185** paesi



Tessuto tumorale, adiacente e normale a confronto


Gadaleta et al., J Pathol, 2022

- Il tessuto adiacente porta **alterazioni epigenetiche precoci**
- Distinguere Normal da Adjacent ha **valore clinico reale**



Il Dato: Metilazione del DNA e Siti CpG

1 Dal Problema Biologico ai Dati



Distribuzione media del β -value per classe

Ogni sito **CpG** produce un valore $\beta \in [0, 1]$

Le **distribuzioni globali** non separano le classi

Piattaforma **Illumina EPIC**

~**866k** siti CpG per campione

495 campioni totali:

295 Normali **200** Adiacenti



Table of Contents


2 Dal Dato Grezzo alla Feature Selection

- ▶ Dal Problema Biologico ai Dati
- ▶ Dal Dato Grezzo alla Feature Selection
- ▶ Dalla Feature Selection al Pannello Finale
- ▶ Conclusioni e Sviluppi Futuri




Preprocessing: dal Rumore al Segnale

2 Dal Dato Grezzo alla Feature Selection



PCA pre-ComBat: Trustworthiness ($k=5$) = **0.73**



PCA post-ComBat: Trustworthiness ($k=5$) = **0.71**


- Rimozione probe **cross-reactive** e **SNP-prossimali**
- Trasformazione $|\beta_{ij} - \bar{\beta}_j^{\text{Normal}}|$: amplifica la deviazione dal tessuto sano
- **NeuroCombat**: $Y_{ijd} = \alpha_j + X\beta_j + \gamma_{jd} + \delta_{jd}\epsilon_{ijd}$

γ_{jd} : batch additivo δ_{jd} : batch moltiplicativo — stimati via Bayes empirico



Riduzione dello Spazio delle Feature


2 Dal Dato Grezzo alla Feature Selection





Stability Ranking

2 Dal Dato Grezzo alla Feature Selection



Candidati selezionati (verde) vs scartati (blu) — cutoff data-driven

50 split (K=5, R=10) per ogni CpG:

$$\text{stability} = \frac{\text{split concordanti}}{\text{split validi}} \geq 0.75$$

Score composito (0.8 stat + 0.2 bio):

$$\text{score_stat} = \frac{1}{2} \overline{\text{rank}}_p + \frac{1}{2} \overline{\text{rank}}_{|\Delta M|}$$

$$\text{score_bio} = \frac{1}{2} (1 - \text{IP}) + \frac{1}{2} (1 - \text{bio_weight})$$



$$\text{IP}_j = \frac{\Delta M(\text{Adj} - \text{Norm})_j}{\Delta M(\text{Tum} - \text{Norm})_j}$$

Cutoff $|\Delta M|$ **data-driven** (elbow cord)
→ **15,659** CpG candidati



Correlation Pruning tramite Grafi

2 Dal Dato Grezzo alla Feature Selection



Pool A: CpG ancorati a *CpG islands* (biologicamente privilegiati)



Table of Contents

3 Dalla Feature Selection al Pannello Finale

- ▶ Dal Problema Biologico ai Dati
- ▶ Dal Dato Grezzo alla Feature Selection
- ▶ Dalla Feature Selection al Pannello Finale
- ▶ Conclusioni e Sviluppi Futuri



Selezione del Pannello: MILP Knapsack

3 Dalla Feature Selection al Pannello Finale

$$\max_x \sum_{j \in \mathcal{J}} v_j x_j + \mu \hat{\Phi}(x, \gamma)$$

$$\hat{\Phi}(x, \gamma) = \frac{1}{K(2 + \eta)} \left(\sum_{j: \text{prom}(j)} x_j + \sum_{j: \text{isl}(j)} x_j + \eta \sum_g \gamma_g \right)$$

$$\text{s.t.} \quad \sum_j x_j = K \quad \cdot \quad x_i + x_j \leq 1 \quad \forall (i, j) : |r_{ij}| \geq 0.85$$

$$\sum_{j \in \mathcal{J}_c} x_j \leq \delta_{\text{chr}} \quad \forall c \quad \cdot \quad \sum_{j \in \mathcal{J}_A} x_j \geq K_A$$

$$x_j \leq \gamma_{g(j)} \quad \forall j \quad \cdot \quad \sum_{j: g(j)=g} x_j \leq \delta_{\text{max}} \quad \forall g$$

$$\sum_g \gamma_g \geq G_{\text{min}} \quad \cdot \quad \sum_{j: \Delta M_j > 0} x_j \geq h_{\text{min}}$$

$$x_j \in \{0, 1\}, \quad \gamma_g \in \{0, 1\}$$



Risultati: il Trade-off Esplicito

3 Dalla Feature Selection al Pannello Finale

	Greedy	Knapsack
CpG selezionati	50	50
AUC	0.982	0.971
BACC	0.919	0.883
COSMIC hits	0/50	15/50
Fisher OR	1.00	175.08
<i>p</i> -value	1.00	1.4×10^{-27}

Wilcoxon knapsack vs greedy:

$p < 0.001$ — differenza statisticamente significativa

Il trade-off:

— 1.1 punti AUC in cambio di OR= 175
L'interpretabilità biologica **non emerge**
dalla performance — è **imposta dai vincoli**

Geni chiave selezionati:

BRCA2 17q21 — DNA repair
TP53 17p13 — oncosoppressore
ERBB2 17q12 — recettore HER2

Convergenza non supervisionata su chr17

KEGG Breast Cancer adj. $p = 2 \times 10^{-6}$



Table of Contents

4 Conclusioni e Sviluppi Futuri

- ▶ Dal Problema Biologico ai Dati
- ▶ Dal Dato Grezzo alla Feature Selection
- ▶ Dalla Feature Selection al Pannello Finale
- ▶ Conclusioni e Sviluppi Futuri



Conclusioni

4 Conclusioni e Sviluppi Futuri

Contributo principale:

Framework end-to-end riproducibile:
da **866k CpG** grezzi a un pannello di **50 CpG**
biologicamente vincolato

- **NeuroCombat** risolve il batch effect preservando il segnale biologico
- Pipeline di feature selection **stabile, non ridondante, genomicamente diversificata**
- **MILP knapsack**: l'interpretabilità biologica è **imposta dai vincoli**, non emerge dalla performance

Risultato centrale:

	Greedy	Knapsack
AUC	0.982	0.971
COSMIC hits	0/50	15/50
Fisher OR	1.00	175.08

Geni selezionati: **TP53, RB1, BRCA2, NOTCH1, HDAC4, LIN28B**

Pathway: KEGG Breast Cancer adj.
 $p = 2 \times 10^{-6}$

"Interpretability is not a by-product of performance — it must be structurally imposed."



Limitazioni e Sviluppi Futuri

4 Conclusioni e Sviluppi Futuri

Limitazioni:

- Validazione su una sola piattaforma (EPIC v1.0)
- Campione moderato ($n = 495$, Adjacent = 200)
- Assenza di validazione su dataset esterno indipendente

Sviluppi futuri:

- Validazione su coorti EPIC indipendenti e cross-platform (EPIC v2, $\sim 930k$ CpG)
- Analisi di sensibilità sui parametri della pipeline (stabilità, τ_c , K)
- Estensione del framework MILP ad altri tipi tumorali
- Integrazione di dati multi-omici per arricchire i vincoli biologici



DNA Methylation Dynamics Along the Normal-Adjacent Axis in Breast Cancer

Grazie mille per l'attenzione!